

*Actividad 1:
Segmentación de clientes
mediante Aprendizaje No
Supervisado*

*Fundamentos de Inteligencia Artificial
para Ingenieros de Software*

Curso 2026-27

Raúl Quirós Morales

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

Índice

1. Introducción.....	3
2. Análisis exploratorio del conjunto de datos.....	3
3. Preprocesamiento.....	5
3.1. Aplicación de técnicas de clustering.....	5
3.2. K-Means y número de grupos.....	6
3.3. DBSCAN.....	6
3.4. Comparación.....	6
4. Visualización y análisis de los resultados.....	7
4.1. Los cinco segmentos de K-Means.....	7
4.2. Perfil de cada grupo.....	7
4.3. Comparación con DBSCAN.....	8
5. Conclusiones y posibles aplicaciones.....	9
6. Referencias.....	10

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

1. Introducción

El objetivo de esta actividad es agrupar a los clientes de un centro comercial según sus características de consumo usando técnicas de aprendizaje no supervisado. La idea es encontrar grupos de clientes parecidos entre sí (segmentos) sin tener etiquetas previas, de modo que esa información pueda servir para tomar decisiones de marketing: a quién dirigir cada campaña, dónde concentrar el presupuesto o qué productos ofrecer a cada perfil.

Se trabaja con el [Mall Customers Dataset](#) de Kaggle, que contiene 200 registros con cuatro variables útiles: el género, la edad, los ingresos anuales (en miles de dólares) y una puntuación de gasto de 1 a 100 que asigna el propio centro. El trabajo sigue los cinco apartados del enunciado: análisis exploratorio, preprocesamiento, clustering, visualización, análisis y conclusiones.

2. Análisis exploratorio del conjunto de datos

Carga. El dataset se descarga directamente de Kaggle con kagglehub y se carga en un DataFrame de pandas. Tiene 200 filas y 5 columnas: CustomerID, Genre, Age, Annual Income (k\$) y Spending Score (1-100).

Calidad de los datos. Se comprueba que no hay valores nulos en ninguna columna.



Variable categórica (género). El reparto es de 112 mujeres (56%) y 88 hombres (44%), es decir, bastante equilibrado con una ligera mayoría femenina.

Variables numéricas. Las estadísticas descriptivas resumen el perfil del conjunto:

	Age	Annual Income (k\$)	Spending Score (1-100)
count	200.000000	200.000000	200.000000
mean	38.850000	60.560000	50.200000
std	13.969007	26.264721	25.823522
min	18.000000	15.000000	1.000000
25%	28.750000	41.500000	34.750000
50%	36.000000	61.500000	50.000000
75%	49.000000	78.000000	73.000000
max	70.000000	137.000000	99.000000

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	


Las distribuciones se representan con histogramas y su curva de densidad. La edad se concentra sobre todo entre los 30 y los 40 años, los ingresos rondan los 60 k\$ y la puntuación de gasto se reparte de forma bastante amplia alrededor de 50.



Valores atípicos. Se revisan con un diagrama de dispersión de ingresos frente a gasto y con diagramas de caja. La puntuación de gasto no presenta puntos fuera de los bigotes. En cambio, en los ingresos aparece un valor por encima del bigote superior (>130k\$). Será tratado como un cliente real de renta alta. Como además es justo el tipo de perfil que puede definir un segmento de interés, se conserva en el análisis y no se elimina.



Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	



Ya en el diagrama de dispersión se intuye que los clientes no forman una nube uniforme, sino varias agrupaciones, lo que adelanta que la segmentación tiene sentido.

3. Preprocesamiento

Selección de variables. Para el clustering se usan solo dos variables: Annual Income (k\$) y Spending Score (1-100), las que describen directamente el comportamiento de consumo. Trabajar con dos variables permite además dibujar los grupos directamente en un plano 2D, sin necesidad de reducir dimensiones. Se descartan CustomerID, que es solo un identificador, y Genre, que al ser categórica no encaja bien en una distancia euclídea. La edad se deja fuera del clustering (aunque sí se analiza en el EDA y se usa después para describir los grupos); su incorporación se plantea como mejora en las conclusiones.

Escalado. Las dos variables están en escalas distintas (los ingresos llegan a 137 y la puntuación a 100), así que se estandarizan con StandardScaler para que las dos pesen igual en el cálculo de distancias. Tras el escalado, cada variable queda con media de 0 y desviación típica 1. El resultado se guarda en el DataFrame `datos_escalados`, que es la entrada de los algoritmos.

3.1. Aplicación de técnicas de clustering

Se entrenan dos algoritmos distintos: K-Means y DBSCAN y se comparan con métricas internas de validación. Todas las métricas se calculan con una misma función, `evaluar_clustering`, que se ha reutilizado del material de la asignatura. Esta función calcula tres métricas y, en el caso de DBSCAN, excluye el ruido antes de medir para no falsear el resultado:


- Silhouette: mide si cada punto está cerca de su grupo y lejos de los demás (mejor cuanto más alto). Es la métrica que se ha utilizado para determinar k.
- Davies-Bouldin: mide cuánto se solapan los grupos (mejor cuanto más bajo).
- Calinski-Harabasz: relación entre separación y compactación (mejor cuanto más alto).

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

3.2. K-Means y número de grupos

K-Means necesita fijar el número de grupos k de antemano. Para elegirlo se entrena K-means con $k = 2$ hasta $k = 8$ (con `random_state=42` y `n_init=20`), guardando la inercia y las métricas en cada caso. El criterio principal para elegir k es Silhouette, porque tiene un óptimo claro (su valor máximo). El elbow solo sirve como apoyo visual (muestra dónde la inercia deja de bajar de forma apreciable).

Para afinar la elección se podría contrastar con otras métricas ya calculadas (Davies-Bouldin y Calinski-Harabasz) y comprobar si coinciden, y/o formalizar el elbow con kneed en lugar de revisarlo a ojo.



Los dos criterios coinciden en $k = 5$: a partir de ahí la inercia deja de bajar de forma apreciable y la Silhouette llega a su máximo ($\approx 0,55$), con la Davies-Bouldin también en su valor más bajo ($\approx 0,57$).

3.3. DBSCAN

DBSCAN no necesita fijar el número de grupos: los descubre por densidad y marca como ruido los puntos que no encajan en ninguna zona densa. Como con K-means, probamos varios valores del parámetro `eps` (de 0,20 a 0,60) con `min_samples=5`. Se ve con claridad que al bajar `eps` aumentan los grupos, pero también el ruido.

3.4. Comparación

Reuniendo los resultados de los dos métodos, las soluciones más representativas (ordenadas por Silhouette descendiente) son:

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	


modelo	parametro	n_clusters	n_ruido	silhouette	davies_bouldin	calinski_harabasz	inercia
DBSCAN	0.20	7	77	0.5856	0.4637	173.2619	NaN
DBSCAN	0.35	6	23	0.5577	0.5106	245.3557	NaN
K-Means	5.00	5	0	0.5547	0.5722	248.6493	65.5684

Si solo se mirara el número, ganaría DBSCAN con $\text{eps} = 0,20$, porque tiene la Silhouette más alta. Pero esa solución lo consigue dejando fuera a 77 de los 200 clientes como ruido, casi un 40%. Para el objetivo de segmentar a toda la clientela, eso no es práctico. K-Means con $k = 5$ reparte a los 200 clientes en 5 grupos sin dejar a nadie fuera y con una Silhouette casi igual de buena, así que es la solución que se lleva al análisis. DBSCAN se mantiene como apoyo, útil sobre todo para señalar qué clientes son atípicos.

4. Visualización y análisis de los resultados

4.1. Los cinco segmentos de K-Means

Al representar la solución de K-Means en el plano de ingresos y gasto, los cinco grupos quedan bien separados. Las estrellas marcan los centroides, devueltos a la escala original para que se lean en sus unidades reales.



4.2. Perfil de cada grupo


Para interpretar los grupos se calcula la media de edad, ingresos y gasto de cada uno, junto con su tamaño. La edad se incluye aunque no se haya usado para agrupar, porque ayuda a describir cada segmento.

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

	n_clientes	edad_media	ingreso_medio	gasto_medio	perfil
Grupo					
0	81	42.7	55.3	49.5	Ingreso y gasto medios
1	39	32.7	86.5	82.1	Ingreso alto y gasto alto
2	22	25.3	25.7	79.4	Ingreso bajo y gasto alto
3	35	41.1	88.2	17.1	Ingreso alto y gasto bajo
4	23	45.2	26.3	20.9	Ingreso bajo y gasto bajo

4.3. Comparación con DBSCAN

Para ver cómo se comporta DBSCAN, se analiza el caso con la segunda mejor métrica de Silhouette ($\text{eps} = 0.35$, Silhouette ≈ 0.56), que detecta seis zonas densas y marca con una "x" a unos 22 clientes como ruido.



Los dos métodos coinciden en las zonas con más densidad de puntos, pero funcionan distinto:

- K-Means reparte a los 200 clientes en 5 grupos de tamaño parecido e incluye la zona central, así que da una segmentación completa.
- DBSCAN saca más grupos (o menos, según el eps que elijamos), y deja como ruido a los clientes que se salen, en vez de meterlos a la fuerza en un grupo. Eso viene bien para detectar grupos muy definidos, e identificar a los clientes "raros" o ambiguos.

Para lo que nos interesa en este caso (agrupar a todos los clientes), nos quedamos con los 5 grupos de K-Means, y dejamos DBSCAN como apoyo.

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

5. Conclusiones y posibles aplicaciones

La segmentación con K-Means ($k = 5$) divide a los 200 clientes en cinco grupos bien diferenciados por sus ingresos y su nivel de gasto. Cada uno se puede leer en clave de negocio:

- **Ingreso alto y gasto alto** (unos 39 clientes, ~33 años de media): son los clientes más rentables: ganan mucho y gastan mucho.
- **Ingreso alto y gasto bajo** (unos 35 clientes, ~41 años): ganan mucho pero gastan poco. Posible margen de mejora.
- **Ingreso bajo y gasto alto** (unos 22 clientes, los más jóvenes, ~25 años): gastan mucho pese a que ganan poco.
- **Ingreso bajo y gasto bajo** (unos 23 clientes, ~45 años): gastan poco y ganan poco.
- **Ingreso y gasto medios** (unos 81 clientes, ~43 años): el grupo más grande, con valores medios en todo.

Aplicaciones reales. Esta segmentación permite hacer marketing dirigido (un mensaje distinto por grupo en vez de una única campaña para todos), concentrar el presupuesto en los segmentos más interesantes (los de ingreso alto), y adaptar productos y precios a cada perfil. Además, como el scaler y el modelo quedan entrenados, un cliente nuevo se puede asignar a su grupo al instante y personalizar la oferta desde el primer momento.

Comparación de métodos. K-Means dio la segmentación más útil y estable: agrupa a todos los clientes en grupos claros y coherentes con lo que se veía en el EDA, y sus métricas (Silhouette y Davies-Bouldin) son buenas justo en $k = 5$. DBSCAN llega a una Silhouette algo mayor, pero solo porque descarta muchos clientes como ruido, así que no sirve como segmentación principal; su valor está en detectar grupos muy definidos y perfiles atípicos.

Limitaciones.

- Solo hemos usado dos variables (ingresos y gasto). La edad y el género se quedan fuera, así que los grupos no recogen la parte demográfica.
- El Spending Score viene ya calculado en el dataset y no sabemos del todo cómo se obtiene.
- Son solo 200 clientes de un único centro, así que los resultados no tienen por qué valer en otro contexto.

Posibles mejoras.

- Meter la edad y el género y, para poder dibujarlo, usar PCA o un gráfico en 3D.
- Probar otros algoritmos (como Agglomerative o Gaussian Mixture) y ver si los grupos salen parecidos.
- Añadir más datos, como el histórico de compras o la frecuencia.
- Validar los grupos con el negocio y medir si las campañas por grupo funcionan.

Asignatura	Datos del alumno	Fecha
Fundamentos de Inteligencia Artificial para Ingenieros de Software	Apellidos: Quirós Morales	26/06/2026
	Nombre: Raúl	

6. Referencias

- Mall Customers Dataset (Kaggle):
 - <https://www.kaggle.com/datasets/shwetabh123/mall-customers>
- Material de la asignatura (Campus Online):
 - <https://campusonline.unir.net/mod/folder/view.php?id=515950>